

UỶ BAN NHÂN DÂN
THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC SÀI GÒN



BÁO CÁO TIỂU LUẬN CUỐI KỲ

Môn học:

Phân Tích Và Nhận Dạng Mẫu

Đề tài:

Dự Đoán Nguy Cơ Mắc Bệnh Tiểu Đường

Giảng viên :

Ts. Vũ Ngọc Thanh Sang
& Th.s Nguyễn Thanh Phước

Sinh viên thực hiện:

3122410040

Đặng Văn chiến

Thành phố Hồ Chí Minh, 12/2024

This image shows a full page of white paper with horizontal dotted lines. The lines are evenly spaced and run across the width of the page, providing a guide for handwriting practice. There are no margins, text, or other markings on the page.

LỜI CẢM ƠN

Để hoàn thành tốt đề tài báo cáo cuối kỳ này, ngoài sự nỗ lực của bản thân, em còn nhận được sự quan tâm giúp đỡ của nhiều tập thể và cá nhân. Trước hết em xin gửi lời cảm ơn trân thành và sự tri ân sâu sắc nhất đến với các thầy cô của trường Đại Học Sài Gòn, đặc biệt là quý thầy cô ở khoa Công Nghệ Thông Tin của trường đã tạo điều kiện cho em học tập và tìm hiểu về môn học cũng như để hoàn thành báo cáo cho môn học Phân tích và nhận dạng mẫu lần này.

Và em cũng xin chân thành cảm ơn thầy Vũ Ngọc Thanh Sang và thầy Nguyễn Thanh Phước , hai giáo viên đã giảng dạy nhiệt tình truyền đạt những kiến thức về môn học cho chúng em để hoàn thành bài báo cáo lần này.

Em xin cảm ơn các anh chị, bạn bè đã đã quan tâm và tiếp thêm sức mạnh, động lực để hoàn thành bài báo cáo này.

Trong quá trình nghiên cứu và làm bài báo cáo đồ án, do kiến thức cũng như kinh nghiệm thực tế còn nhiều hạn chế nên bài báo cáo không thể tránh khỏi những thiếu sót, em rất mong nhận được ý kiến đóng góp thầy, cô để em học hỏi được nhiều kỹ năng, kinh nghiệm và sẽ hoàn thành tốt hơn cho những bài báo cáo sắp tới.

Em xin chân thành cảm ơn !

Mục Lục

Phần I. Giới thiệu	1
1. Đặt vấn đề	1
2. Định nghĩa bài toán	1
3. Đặt giả thiết	2
4. Các bài toán tương tự trong thực tế	2
5. Phương pháp tiếp cận	3
Phần II. Chuẩn bị dữ liệu	3
1. Giới thiệu về bộ dữ liệu	3
2. Bảng mô các đặc trưng	4
Phần III. Xử lý dữ liệu	5
1. Xử lý dữ liệu trùng lặp	5
2. Giá trị thiếu	6
3. Giá trị ngoại lệ	6
Phần IV. Phân tích dữ liệu	7
1. Phân tích tỉ lệ mắc bệnh tiểu đường	7
2. Các đặc trưng các mối tương quan mạnh đối với bệnh tiểu đường	8
3. Các đặc trưng chung	9
3.1 Ảnh hưởng của HightHB	9
3.2. Ảnh hưởng của HighChol	11
3.4. HighBp và HighChol với Bệnh tiểu đường	12
3.5. Chỉ số khối cơ thể BMI	13
3.6. Smoker(Hút thuốc)	14
4. Các yếu tố liên quan đến sức khỏe	17
4.1. Đột quy (Stroke)	17
4.2. Mối liên hệ với bệnh tim	18
4.3. Mối liên hệ với mức độ tổng quát sức khỏe (GenHlth)	19
4.4. Mối liên hệ với sức khỏe tâm lý (MentHlth)	20

4.5. Mối liên hệ với thể chất (PhysHlth)	21
4.6. Mối liên hệ với việc đi lại	22
4.7. Mối liên hệ người sử dụng dịch vụ y tế	23
5. Các vấn đề liên quan đến phong cách sống	25
5.1. Hoạt động thể chất (PhysActivity)	25
5.2. Mối liên hệ với việc ăn rau và hoa quả (thực phẩm)	26
6. Các đặc trưng xã hội.....	27
6.1. Mối liên hệ với độ tuổi.....	27
6.2. Mối liên hệ với trình độ học vấn và thu nhập gia đình.....	29
Phần V. Lựa chọn đặc trưng.....	29
1. Giới thiệu về lựa chọn đặc trưng	29
2. Lựa chọn đặc trưng	29
2.1 Pearson Correlation.....	29
2.2 Giá trị Thông tin (IV)	31
2.3 Phương pháp loại bỏ đệ quy Recursive Feature Elimination (RFE).....	32
Phần VI. Huấn luyện mô hình	34
1. Chia dữ liệu huấn luyện	34
2. Huấn luyện mô hình cây quyết định	36
2.1 Lý do chọn mô hình randomforest cho bài toán.....	36
2.2 Huấn luyện mô hình.	36
Phần VII. Đánh giá mô hình.....	37
1. Phép đo sử dụng đánh giá	37
2. Đánh giá kết quả	38
Phần VIII. Tinh chỉnh mô hình	39
1. Tìm bộ tham số tối ưu.....	39
2. Huấn luyện lại mô hình với tham số tối ưu.....	41
Phần IX. Kết luận	42
1. Tóm tắt	42
2. Hạn chế và hướng phát triển.....	42

3. Kết luận chung	43
Tài liệu tham khảo	44

Danh mục hình ảnh

Hình 1. Xử lý dữ liệu trùng lặp	5
Hình 2. Kiểm tra giá trị bị thiếu	6
Hình 3. Số giá trị của các đặc trưng	7
Hình 4. Tỷ lệ mắc bệnh tiểu đường	8
Hình 5. biểu đồ mức độ ảnh hưởng của các đặc trưng đối với bệnh tiểu đường	9
Hình 6. Biểu đồ tần suất giữa bệnh tiểu đường và highbp	10
Hình 7. Tỷ lệ mắc bệnh tiểu đường với HighBP	11
Hình 8. Mối liên hệ giữa Cholesterol cao và Tiểu đường	12
Hình 9. Mối liên hệ của cholesterol và HighPb với bệnh tiểu đường	13
Hình 10. Mối liên hệ giữa BMI và nguy cơ tiểu đường	14
Hình 11. Mối liên hệ giữa hút thuốc và bệnh tiểu đường.	15
Hình 12. Tỷ lệ người nghiện rượu	16
Hình 13. Mối liên hệ giữa hút thuốc và nghiện rượu với bệnh tiểu đường.	16
Hình 14. Tỷ lệ người bị đột nguy	17
Hình 15. Mối liên hệ đột nguy với bệnh tiểu đường.	18
Hình 16. Mối liên hệ bệnh tim với bệnh tiểu đường	19
Hình 17. Mối liên hệ giữa sức khỏe và bệnh tiểu đường.	20
Hình 18. Mối liên hệ giữa sức khỏe tâm thần với bệnh tiểu đường.	21
Hình 19. Mối liên hệ giữa sức khỏe thể chất và bệnh tiểu đường.	22
Hình 20. Mối liên hệ giữa việc đi lại với bệnh tiểu đường.	23
Hình 21. Mối liên hệ giữa việc sử dụng dịch vụ y tế và bệnh tiểu đường.	24
Hình 22. Mối liên hệ mắc bệnh tiểu đường ở nhóm có và không có chi phí y tế	25
Hình 23. Mối liên hệ giữa việc hoạt động thể chất với bệnh tiểu đường	26
Hình 24. Mối liên hệ giữa việc ăn thực phẩm trong ngày với bệnh tiểu đường	26
Hình 25. Mối liên hệ giữa nhóm độ tuổi và bệnh tiểu đường	27
Hình 26. Mối liên hệ giữa nhóm độ tuổi và bệnh tiểu đường	28
Hình 27. Mối liên hệ giữa học vấn và thu nhập gia đình với bệnh tiểu đường.	29
Hình 28. Hệ số tương quan của các đặc trưng với bệnh tiểu đường	30
Hình 29. Giá trị thông tin các đặc trưng với bệnh tiểu đường	32
Hình 30. Các đặc trưng quan trọng sau khi chọn lọc	33
Hình 31. Kết quả tinh chỉnh	41

Danh Mục Bảng

Bảng 1 Mô tả các đặc trưng của dữ liệu	5
Bảng 2. Các nhóm độ tuổi.	27
Bảng 3. Khả năng dự đoán giá trị thông tin	31
Bảng 4. So sánh hiệu suất mô hình	38

Phần I. Giới thiệu

1. Đặt vấn đề

Bệnh tiểu đường đang trở thành một vấn đề sức khỏe công cộng lớn trên toàn thế giới, với số lượng người mắc bệnh ngày càng gia tăng. Theo thống kê toàn cầu, tính đến năm 2021, khoảng 529 triệu người đang sống với bệnh tiểu đường, với tỷ lệ mắc bệnh khoảng 6.1% [1]. Xu hướng này không chỉ diễn ra ở các nước phát triển mà còn tăng nhanh ở các quốc gia đang phát triển, nơi điều kiện dinh dưỡng và lối sống đang thay đổi nhanh chóng.

Bệnh tiểu đường, hay còn gọi là đái tháo đường, là một nhóm các bệnh chuyển hóa đặc trưng bởi mức đường huyết (glucose) trong máu cao, do cơ thể không sản xuất đủ insulin hoặc không thể sử dụng insulin một cách hiệu quả. Có hai loại tiểu đường chính là tiểu đường loại 1 (do thiếu insulin hoàn toàn) và tiểu đường loại 2 (do cơ thể không sử dụng insulin hiệu quả) [2]. Bệnh tiểu đường có thể dẫn đến nhiều biến chứng nguy hiểm, làm giảm đáng kể chất lượng cuộc sống và thậm chí gây tử vong. Các biến chứng thường gặp bao gồm bệnh tim mạch, đột quỵ, suy thận, mù lòa, nhiễm trùng, và tổn thương thần kinh. Những biến chứng này còn tạo ra gánh nặng kinh tế đáng kể cho cá nhân, gia đình và xã hội. Theo ước tính, chi phí y tế trực tiếp và gián tiếp do bệnh tiểu đường gây ra lên tới hàng trăm tỷ đô la mỗi năm.[3]

Tuy nhiên, việc chẩn đoán bệnh tiểu đường thường dựa vào các xét nghiệm y tế tốn kém và mất thời gian. Do đó, việc phát triển một mô hình dự đoán bệnh tiểu đường dựa trên các yếu tố nguy cơ có thể tiếp cận dễ dàng là rất cần thiết. Mô hình này có thể giúp các bác sĩ và bệnh nhân xác định nguy cơ mắc bệnh tiểu đường, từ đó đưa ra các biện pháp phòng ngừa và điều trị kịp thời, góp phần giảm thiểu gánh nặng của bệnh tiểu đường đối với sức khỏe cộng đồng.

2. Định nghĩa bài toán

Bài toán đặt ra là tìm hiểu các vấn đề liên quan đến bệnh tiểu đường và xây dựng một mô hình dự đoán bệnh tiểu đường dựa trên các yếu tố nguy cơ có sẵn trong bộ dữ liệu "diabetes_binary_health_indicators_BRFSS2015.csv". Bộ dữ liệu này bao gồm các thông tin về lối sống, sức khỏe và nhân khẩu học, được

thiết kế để phục vụ nghiên cứu về các yếu tố nguy cơ sức khỏe. Mô hình này sẽ sử dụng các đặc trưng này để dự đoán xem họ có nguy cơ mắc bệnh tiểu đường hay không.

3. Đặt giả thiết

Để xây dựng mô hình dự đoán bệnh tiểu đường hiệu quả, chúng em đưa ra một số giả thiết sau:

- Các yếu tố nguy cơ được thu thập trong bộ dữ liệu là đại diện cho các yếu tố nguy cơ chính của bệnh tiểu đường.
- Các thuật toán học máy có thể mô hình hóa mối quan hệ giữa yếu tố nguy cơ và bệnh tiểu đường.
- Mô hình dự đoán được xây dựng sẽ có độ chính xác cao và có thể áp dụng trong thực tế.

4. Các bài toán tương tự trong thực tế

Bài toán dự đoán bệnh tiểu đường có nhiều điểm tương đồng với các bài toán dự đoán khác trong lĩnh vực y tế, chẳng hạn như:

1) Phát hiện suy giảm sức khỏe trong ICU

Trong lĩnh vực chăm sóc tích cực, thuật toán học máy đã được triển khai để dự đoán khả năng suy giảm sức khỏe của bệnh nhân. Ví dụ, tại Mỹ, một bệnh viện sử dụng hệ thống dự đoán sự xấu đi của bệnh nhân ICU đã giảm 35% sự cố nghiêm trọng và hơn 86% tỷ lệ ngừng tim [4].

2) Chẩn đoán ung vú

Các thuật toán học máy đã được sử dụng trong phân tích hình ảnh y tế để phát hiện ung thư. Tại một trung tâm nghiên cứu ung thư hàng đầu, AI đã giúp phát hiện ung thư vú với độ chính xác cao hơn 9,4% so với bác sĩ chẩn đoán bằng mắt thường [5].

3) Ứng dụng dự đoán COVID-19

Một tổ chức chăm sóc sức khỏe tại Mỹ đã sử dụng học máy để xác định bệnh nhân có nguy cơ cao phát triển biến chứng nặng do COVID-19. Điều này cho phép họ tập trung hỗ trợ y tế vào nhóm có nguy cơ cao, giảm gánh nặng cho các bác sĩ và nhân viên y tế [6].

5. Phương pháp tiếp cận

Bài báo cáo sử dụng phương pháp phân tích dữ liệu (EDA) để khám phá các đặc điểm chính của dữ liệu, áp dụng các thuật toán học máy phổ biến, và sử dụng các chỉ số đánh giá hiệu suất như độ chính xác, F1-score và Accuracy để đánh giá kết quả của mô hình. Đóng góp chính của nghiên cứu là cung cấp một mô hình dự đoán có thể dễ dàng áp dụng trong thực tế và cải thiện khả năng sàng lọc bệnh tiểu đường ở cấp độ cộng đồng.

Phần II. Chuẩn bị dữ liệu

1. Giới thiệu về bộ dữ liệu

Nguồn gốc

Bộ dữ liệu được sử dụng trong bài nghiên cứu này là "diabetes_binary_health_indicators_BRFSS2015.csv". Bộ dữ liệu được tạo bởi Alex Teboul dựa trên dữ liệu gốc từ BRFSS 2015 và công khai trên nền tảng Kaggle: [/kaggle/input/cdc-diabetes-health-indicators/diabetes_binary_health_indicators_BRFSS2015.csv]. Bộ dữ liệu được hơn 600 lượt bình chọn và hơn 82 000 lượt tải về trên nền tảng Kaggle.[7]

Nguồn gốc bộ dữ liệu là được thu thập từ Hệ thống Giám sát Yếu tố Nguy cơ Hành vi BRFSS (Behavioral Risk Factor Surveillance System) năm 2015. BRFSS là một cuộc khảo sát điện thoại hàng năm được thực hiện bởi Trung tâm Kiểm soát và Phòng ngừa Dịch bệnh Hoa Kỳ (CDC) nhằm thu thập thông tin về sức khỏe và các yếu tố nguy cơ hành vi của người trưởng thành trên khắp Hoa Kỳ.

Đặc điểm:

- Bộ dữ liệu chứa 253,680 dòng dữ liệu, mỗi dòng dữ liệu đại diện cho một người tham gia khảo sát.
- Có 22 cột, bao gồm 21 đặc trưng (features) và 1 biến mục tiêu (target variable).
- Các đặc trưng bao gồm thông tin về lối sống, sức khỏe và nhân khẩu học của người tham gia.

- Biến mục tiêu là "Diabetes_binary", chỉ ra người tham gia có mắc bệnh tiểu đường (1) hay không (0).
- Bộ dữ liệu đã được làm sạch và xử lý sơ bộ bởi Alex Teboul.
- Các biến phân loại đã được mã hóa thành dạng số.

Mục tiêu sử dụng:

- Bộ dữ liệu này sẽ được sử dụng để phân tích các đặc trưng nguy cơ có liên quan đến bệnh tiểu đường và xây dựng một mô hình dự đoán bệnh tiểu đường dựa trên các đặc trưng được thu thập.

2. Bảng mô các đặc trưng

STT	Đặc trưng	Mô tả	Kiểu dữ liệu	Giá trị
1	Diabetes_binary	Biến mục tiêu, chỉ ra người tham gia có mắc bệnh tiểu đường hay không	Nhị phân	0: Không, 1: Có
2	HighBP	Người tham gia có bị huyết áp cao hay không	Nhị phân	0: Không 1: Có
3	HighChol	Người tham gia có bị cholesterol cao hay không	Nhị phân	0: Không 1: Có
4	CholCheck	Người tham gia có kiểm tra cholesterol trong 5 năm qua hay không	Nhị phân	0: Không 1: Có
5	BMI	Chỉ số khối cơ thể của người tham gia	Số nguyên	Xác định
6	Smoker	Có hút thuốc hay không (ít nhất 100 điếu)	Nhị phân	0: Không 1: Có
7	Stroke	Người tham gia có bị đột quỵ hay không	Nhị phân	0: Không 1: Có
8	HeartDiseaseor Attack	Người tham gia có bị bệnh tim hoặc đau tim hay không	Nhị phân	0: Không 1: Có
9	PhysActivity	Người tham gia có hoạt động thể chất trong 30 ngày qua hay không	Nhị phân	0: Không 1: Có
10	Fruits	Người tham gia có ăn trái cây 1 lần/ngày trở lên hay không	Nhị phân	0: Không 1: Có
11	Veggies	Người tham gia có ăn rau 1 lần/ngày trở lên hay không	Nhị phân	0: Không 1: Có
12	HvyAlcoholConsump	Người tham gia có nghiện rượu rượu bia hay không (nam >14 ly/tuần, nữ >7 ly/tuần)	Nhị phân	0: Không 1: Có
13	AnyHealthcare	Người tham gia có bảo hiểm y tế hoặc kế hoạch chăm sóc sức khỏe hay không	Nhị phân	0: Không 1: Có

14	NoDocbcCost	Người tham gia có không khám bệnh vì chi phí hay không	Nhị phân	0: Không 1: Có
15	GenHlth	Đánh giá sức khỏe tổng quát của người tham gia	Số nguyên	1-5 (từ rất tốt đến rất kém)
16	MentHlth	Số ngày sức khỏe tâm lý không tốt trong 30 ngày qua (bao gồm căng thẳng, trầm cảm và các vấn đề về cảm xúc)	Số nguyên	0-30
17	PhysHlth	Số ngày sức khỏe thể chất không tốt trong 30 ngày qua (đau ốm và chấn thương thể chất)	Số nguyên	0-30
18	Diffwalk	Gặp khó khăn trong đi bộ	Nhị phân	0: Không 1: Có
19	Sex	Giới tính (nam/ nữ)	Nhị phân	0: nữ, 1: nam
20	Age	Độ tuổi (Phân nhóm theo AGE5YR)	Số nguyên	1-13
	Education	Trình độ học vấn cao nhất đã hoàn thành (phân nhóm theo EDUCA)	Số nguyên	1-6
22	Income	Thu nhập hộ gia đình (phân nhóm theo INCOME2)	Số nguyên	1-8

Bảng 1 Mô tả các đặc trưng của dữ liệu

Phần III. Xử lý dữ liệu

1. Xử lý dữ liệu trùng lặp

Bộ dữ liệu ban đầu có thể chứa các bản ghi trùng lặp. Để đảm bảo tính toàn vẹn và tránh sai lệch trong quá trình huấn luyện mô hình, chúng ta cần kiểm tra và xử lý các dữ liệu trùng lặp này.

```

# Kiểm tra số lượng bản ghi trùng lặp
num_duplicates = df.duplicated().sum()
print(f"Số lượng bản ghi trùng lặp: {num_duplicates}")

# Xóa bỏ các bản ghi trùng lặp
df.drop_duplicates(inplace=True)
print(f"Kích thước bộ dữ liệu sau khi xóa bản ghi trùng lặp: {df.shape}")

```

Số lượng bản ghi trùng lặp: 24206
 Kích thước bộ dữ liệu sau khi xóa bản ghi trùng lặp: (229474, 22)

Hình 1. Xử lý dữ liệu trùng lặp

Kết quả cho thấy có 24206 bản ghi trùng lặp trong bộ dữ liệu, vì dữ liệu trùng lặp khá ít (khoảng 4,6 %) nên em quyết định xóa bỏ các dữ liệu này, kích thước bộ dữ liệu giảm xuống còn 229474 dòng dữ liệu.

2. Giá trị thiếu


```
#kiểm tra giá trị null
print(df.isnull().sum())
```

Diabetes_binary	0
HighBP	0
HighChol	0
CholCheck	0
BMI	0
Smoker	0
Stroke	0
HeartDiseaseorAttack	0
PhysActivity	0
Fruits	0
Veggies	0
HvyAlcoholConsump	0
AnyHealthcare	0
NoDocbcCost	0
GenHlth	0
MentHlth	0
PhysHlth	0
DiffWalk	0
Sex	0
Age	0
Education	0
Income	0
dtype: int64	

Hình 2. Kiểm tra giá trị bị thiếu

Vì phần dữ liệu trước đó đã được tác giả xử lý một phần nên kết quả cho thấy dữ liệu không có dữ liệu thiếu nào trong bộ dữ liệu. Do đó chúng ta không cần xử lý thêm bước xử lý thiếu nào.

3. Giá trị ngoại lệ




Hình 3. Số giá trị của các đặc trưng

Trong bộ dữ liệu các đặc trưng chủ yếu có giá trị là biến nhị phân nên chủ yếu sẽ có 2 giá trị duy nhất. Mặc dù ta thấy có một số giá trị bất thường dữ liệu ngoại lai (**outlier**) trong dữ liệu của các đặc trưng: **BMI**, **Mental_Health** (sức khỏe tinh thần) và **physical_health** (sức khỏe thể chất), nhưng chúng vẫn được coi là hợp lệ vì chúng phù hợp với phân phối chuẩn (**gaussian distribution**) và về mặt logic, Việc loại bỏ những điểm ngoại lai này đôi khi có thể làm mất đi thông tin quan trọng, đặc biệt khi chúng phản ánh đúng hiện tượng trong thực tế. Do đó, chúng em quyết định không loại bỏ chúng (không coi là outlier cần xử lý).

Phần IV. Phân tích dữ liệu

1. Phân tích tỉ lệ mắc bệnh tiểu đường




Hình 4. Tỷ lệ mắc bệnh tiểu đường

Kết quả: Tỷ lệ số lượng người không mắc bệnh tiểu đường nhiều hơn số lượng người mắc bệnh tiểu đường trong tập dữ liệu của chúng ta cho thấy dữ liệu không công bằng nhưng điều này lại phù hợp với xu hướng mắc bệnh trong thực tế.

2. Các đặc trưng các mối tương quan mạnh đối với bệnh tiểu đường

Để xác định các đặc trưng nào có ảnh hưởng đến bệnh tiểu đường chúng ta sẽ vẽ biểu đồ hiển thị hệ số tương quan giữa các đặc trưng trong tập dữ liệu và biến mục tiêu **Diabetes_binary** (xác định nguy cơ mắc bệnh tiểu đường).



Hình 5. biểu đồ mức độ ảnh hưởng của các đặc trưng đối với bệnh tiểu đường


Kết quả biểu đồ tương quan cho thấy các đặc trưng **GenHlth**, **HighBP**, **DiffWalk**, **BMI**, **HighChol**, **Age**, **HeartDiseaseorAttack**, **PhysHlth**, **income...** có ảnh hưởng mạnh đến bệnh tiểu đường.

Để tìm hiểu chi tiết hơn về các đặc trưng với bệnh tiểu đường. Ở phần tiếp theo em sử dụng các biểu đồ để trực quan hóa phân tích để tìm hiểu rõ hơn về tác động của từng đặc trưng đối với bệnh tiểu đường.

3. Các đặc trưng chung


3.1 Ảnh hưởng của HightHB

HighBP : Đặc trưng này cho biết người được khảo sát có bị huyết áp cao hay không (1: Có, 0: Không).



Hình 6. Biểu đồ tần xuất giữa bệnh tiểu đường và highbp

- **Người bị huyết áp cao có nguy cơ mắc bệnh tiểu đường cao hơn:** Khi so sánh hàng ngang, ta thấy tỷ lệ người bị tiểu đường ở nhóm có huyết áp cao (25.33%) cao hơn đáng kể so với nhóm không bị huyết áp cao (6.94%).
- **Người mắc bệnh tiểu đường cũng có xu hướng bị huyết áp cao:** Khi so sánh cột dọc, ta thấy tỷ lệ người bị huyết áp cao ở nhóm mắc bệnh tiểu đường (74.67%) cao hơn so với nhóm không mắc bệnh tiểu đường (93.06%)




Hình 7. Tỷ lệ mắc bệnh tiểu đường với HighBP

- **Nhóm không bị huyết áp cao (HighBP = 0):**
 - Phần lớn người trong nhóm này không mắc bệnh tiểu đường (cột màu xanh lam cao).
 - Tỷ lệ người mắc bệnh tiểu đường trong nhóm này tương đối thấp (cột màu cam thấp).
- **Nhóm bị huyết áp cao (HighBP = 1):**
 - Tỷ lệ người mắc bệnh tiểu đường trong nhóm này cao hơn đáng kể so với nhóm không bị huyết áp cao (cột màu cam cao hơn).
 - Tuy nhiên, vẫn có một tỷ lệ đáng kể người bị huyết áp cao nhưng không mắc bệnh tiểu đường (cột màu xanh lam).

3.2. Ảnh hưởng của HighChol

HighChol: Đặc trưng này cho biết người được khảo sát có bị cholesterol cao hay không (1: Có, 0: Không).




Hình 8. Mối liên hệ giữa Cholesterol cao và Tiểu đường

- **Người có cholesterol cao có nguy cơ mắc bệnh tiểu đường cao hơn:** Khi so sánh hàng ngang, ta thấy tỷ lệ người bị tiểu đường ở nhóm có cholesterol cao (23.18%) cao hơn đáng kể so với nhóm không có cholesterol cao (9.05%).
- **Người mắc bệnh tiểu đường cũng có xu hướng có cholesterol cao:** Khi so sánh cột dọc, ta thấy tỷ lệ người có cholesterol cao ở nhóm mắc bệnh tiểu đường (76.82%) cao hơn so với nhóm không mắc bệnh tiểu đường (90.95%).

3.4. HighBp và HighChol với Bệnh tiểu đường

Qua phân phân tích 2 yếu tố trên đều thấy người có HighBp(huyết áp cao) và HighChol đều có nguy cơ cao sẽ mắc bệnh tiểu đường, vậy liệu một người đều có cả 2 yếu tố này thì nguy cơ mắc bệnh tiểu đường của người đó sẽ tăng lên hay không ?. Biểu đồ sau sẽ giúp chúng ta hiểu rõ hơn về điều đó.




Hình 9. Mối liên hệ của cholesterol và HighPb với bệnh tiểu đường

Tác động kết hợp của cholesterol cao và huyết áp cao:

- **Nguy cơ cao nhất:** Nhóm người có cả cholesterol cao và huyết áp cao (1,1) có tỷ lệ mắc bệnh tiểu đường cao nhất (30.65%). Điều này cho thấy sự kết hợp của hai yếu tố nguy cơ này làm tăng đáng kể nguy cơ mắc bệnh tiểu đường.
- **Nguy cơ thấp nhất:** Nhóm người không có cả cholesterol cao và huyết áp cao (0,0) có tỷ lệ mắc bệnh tiểu đường thấp nhất (4.94%).
- Biểu đồ này cung cấp bằng chứng mạnh mẽ cho thấy cả cholesterol cao và huyết áp cao đều là những yếu tố nguy cơ quan trọng đối với bệnh tiểu đường, và tác động của chúng được tăng cường khi kết hợp với nhau. Điều này nhấn mạnh tầm quan trọng của việc kiểm soát cả hai yếu tố này để phòng ngừa bệnh tiểu đường.

3.5. Chỉ số khối cơ thể BMI

BMI (Body Mass Index hay chỉ số khối cơ thể) là một chỉ số dùng để đánh giá tình trạng cơ thể của một người dựa trên cân nặng và chiều cao. Công thức tính BMI là cân nặng (kg) chia cho bình phương chiều cao (mét). Thông qua việc tính chỉ số BMI, ta có thể nhận định mức độ gầy hay béo của cơ thể.




Hình 10. Mối liên hệ giữa BMI và nguy cơ tiểu đường

Kết quả: phân bố BMI, đa số người trong mẫu dữ liệu có chỉ số BMI nằm trong khoảng từ 20 đến 40, đây là khoảng BMI bình thường và thừa cân., nhưng đây cũng là khoảng có nhiều điểm dữ liệu nhất :

- Điều này có nghĩa là mối quan hệ giữa BMI và bệnh tiểu đường là không rõ ràng.
- Có thể số ca mắc bệnh tiểu đường cao hơn trong phạm vi này là do có nhiều người hơn trong phạm vi này.
- Tuy nhiên, cũng có thể có mối quan hệ thực sự giữa BMI và bệnh tiểu đường trong phạm vi này.

3.6. Smoker(Hút thuốc)

Smoker: Đặc trưng này cho biết người được khảo sát có hút thuốc hay không (1: Có, 0: Không).




Hình 11. Mối liên hệ giữa hút thuốc và bệnh tiểu đường.

Kết quả:

- **Người hút thuốc có nguy cơ mắc bệnh tiểu đường cao hơn:** Khi so sánh hàng ngang, ta thấy tỷ lệ người bị tiểu đường ở nhóm hút thuốc (17.05%) cao hơn so với nhóm không hút thuốc (13.77%).
- **Tuy nhiên, sự khác biệt không quá lớn:** Mặc dù có sự khác biệt về tỷ lệ mắc bệnh, nhưng sự khác biệt này không quá lớn. Điều này cho thấy hút thuốc là một yếu tố nguy cơ nhỏ, không phải là yếu tố nguy cơ hàng đầu cho bệnh tiểu đường.

3.7. Người hút thuốc và uống rượu


HvyAlcoholConsump : Người nghiện rượu nặng (đàn ông trưởng thành uống hơn 14 ly mỗi tuần và phụ nữ trưởng thành uống hơn 7 ly mỗi tuần)(0,1)



Hình 12. Tỷ lệ người nghiện rượu.

Dữ liệu về HvyAlcoholConsump cho thấy đang bị mất cân bằng, không thể rút ra kết luận đáng tin cậy với biến mục tiêu. Thay vào đó chúng ta sẽ cùng phân tích xem người vừa hút thuốc và vừa nghiện rượu liệu có tác động mạnh đến bệnh tiểu đường thông qua phân tích biểu đồ kết hợp sau.

Cross-Tabulation: HvyAlcoholConsump & Smoker vs Diabetes_binary (%)




Hình 13. Mối liên hệ giữa hút thuốc và nghiện rượu với bệnh tiểu đường.

Kết quả: Nhóm người vừa tiêu thụ rượu nặng vừa hút thuốc (1,1) có tỷ lệ mắc bệnh tiểu đường cao nhất (6.78%). Điều này cho thấy sự kết hợp của hai thói quen này làm tăng đáng kể nguy cơ mắc bệnh tiểu đường.

4. Các yếu tố liên quan đến sức khỏe


4.1. Đột quỵ (Stroke)

Stroke: người này đã từng bị đột quỵ không (1: có,0: không).



Hình 14. Tỷ lệ người bị đột quỵ.

Qua biểu đồ có thể thấy dữ liệu về số người bị đột quỵ đang bị mất cân bằng, nhưng số liệu này sẽ được phân tích độc lập vì mối quan hệ giữa đột quỵ với bệnh tiểu đường đã rõ ràng.[6]




Hình 15. Mối liên hệ đột quỵ với bệnh tiểu đường.

Kết quả: Bệnh tiểu đường là yếu tố nguy cơ chính gây đột quỵ. Những người mắc bệnh tiểu đường có nguy cơ bị đột quỵ cao gấp đôi so với những người không mắc bệnh tiểu đường. Điều này là do bệnh tiểu đường làm tổn thương các mạch máu, khiến chúng dễ bị đông máu và cản trở lưu lượng máu đến não.

4.2. Mối liên hệ với bệnh tim

HeartDiseaseorAttack : Những người trả lời đã từng báo cáo mắc bệnh tim mạch vành (CHD) hoặc nhồi máu cơ tim (MI) (0,1).




Hình 16. Mối liên hệ bệnh tim với bệnh tiểu đường.

Kết quả: Theo dữ liệu, bệnh tim cũng có thể dẫn đến bệnh tiểu đường. Những người từng bị đau tim hoặc đột quỵ có nhiều khả năng mắc bệnh tiểu đường sau này.

4.3. Mối liên hệ với mức độ tổng quát sức khỏe (GenHlth)

GenHlth : Nhìn chung về sức khỏe của bạn là: (1 ~ 5)




Hình 17. Mối liên hệ giữa sức khỏe và bệnh tiểu đường.

Kết quả: Theo số liệu, chỉ số sức khỏe tổng quát tỷ lệ thuận với bệnh Tiểu đường. Người có sức khỏe yếu càng yếu (mức 4,5) càng dễ mắc bệnh tiểu đường và ngược lại người có sức khỏe tốt (mức 1 , 2 thì ít bị bệnh tiểu đường hơn).

4.4. Mối liên hệ với sức khỏe tâm lý (MentHlth)

MentHlth : sức khỏe tâm thần của bạn, bao gồm căng thẳng, trầm cảm và các vấn đề về cảm xúc, sức khỏe tâm thần của bạn không tốt trong bao nhiêu ngày trong 30 ngày qua? (0 ~ 30).




Hình 18. Mối liên hệ giữa sức khỏe tâm thần với bệnh tiểu đường.

Kết quả:

- Những người có sức khỏe tâm thần kém có nguy cơ mắc bệnh tiểu đường cao hơn. Nguy cơ phát triển bệnh tiểu đường thậm chí còn cao hơn đối với những người có sức khỏe tâm thần kém kéo dài.
- Tuy nhiên mối liên hệ này không phải là tuyệt đối, điều này có thể là do sức khỏe tâm thần kém có thể dẫn đến lựa chọn lối sống không lành mạnh, chẳng hạn như ăn quá nhiều, hút thuốc và không hoạt động thể chất.

4.5. Mối liên hệ với thể chất (PhysHlth)

PhysHlth: sức khỏe thể chất của bạn, bao gồm bệnh tật và chấn thương thể chất, trong 30 ngày qua sức khỏe thể chất của bạn không tốt trong bao nhiêu ngày? (0 ~ 30)




Hình 19. Mối liên hệ giữa sức khỏe thể chất và bệnh tiểu đường.

Kết quả: biểu đồ cho thấy cả hai đường phân phối đường phân phối (màu xanh) bị tiểu đường nào cao hơn nằm ở vị trí có giá trị PhysHlth lớn hơn. Cho thấy xu hướng người mắc bệnh tiểu thường có vấn đề về sức khỏe không tốt.

4.6. Mối liên hệ với việc đi lại

DiffWalk : Bạn có gặp khó khăn nghiêm trọng khi đi bộ hoặc leo cầu thang không? (0,1)




Hình 20. Mối liên hệ giữa việc đi lại với bệnh tiểu đường.

Kết quả: qua biểu đồ cho thấy người bệnh đái tháo đường gặp khó khăn khi đi lại, leo cầu thang hoặc ngược lại.

4.7. Mối liên hệ người sử dụng dịch vụ y tế

AnyHealthcare : Bạn có bất kỳ loại bảo hiểm chăm sóc sức khỏe nào không, bao gồm bảo hiểm y tế, các chương trình trả trước như HMO hoặc các chương trình của chính phủ như Medicare hoặc Dịch vụ Y tế Ấn Độ? (0,1)




Hình 21. Mối liên hệ giữa việc sử dụng dịch vụ y tế và bệnh tiểu đường.

Kết quả cho thấy không có sự chênh lệch nhiều giữa người sử dụng các dịch vụ y tế và sử dụng dịch vụ có ảnh hưởng nhiều đến người mắc bệnh tiểu đường.

4.8. Mối liên hệ với NoDocbcCost

NoDocbcCost : Có thời điểm nào trong 12 tháng qua bạn cần gặp bác sĩ nhưng không thể vì chi phí không? (0,1)




Hình 22. Mối liên hệ mắc bệnh tiểu đường ở nhóm có và không có chi phí y tế.

Kết quả cho việc không thăm khám bác sĩ vì không đủ chi phí trong 12 tháng qua cũng không có mối liên hệ nhiều với bệnh tiểu đường.

5. Các vấn đề liên quan đến phong cách sống

5.1. Hoạt động thể chất (PhysActivity)


PhysActivity : Người trưởng thành cho biết đã thực hiện hoạt động thể chất hoặc tập thể dục trong 30 ngày qua ngoài công việc thường xuyên của họ (0,1)



Hình 23. Mối liên hệ giữa việc hoạt động thể chất với bệnh tiểu đường.

Kết quả: Hoạt động thể chất thường xuyên có liên quan đến việc giảm nguy cơ mắc bệnh tiểu đường.

5.2. Mối liên hệ với việc ăn rau và hoa quả (thực phẩm)



Hình 24. Mối liên hệ giữa việc ăn thực phẩm trong ngày với bệnh tiểu đường.


Kết quả: việc ăn rau hay hoa quả (thực phẩm) trong ngày không thấy được có mối liên hệ nhiều với bệnh tiểu đường.

6. Các đặc trưng xã hội


6.1. Mối liên hệ với độ tuổi

Category	1	2	3	4	5	6	7	8	9	10	11	12	13
Age range	18-24	25-29	30-34	35-39	40-44	45-49	50-54	55-59	60-64	65-69	70-74	75-79	80+

Bảng 2. Các nhóm độ tuổi.




Hình 25. Mối liên hệ giữa nhóm độ tuổi và bệnh tiểu đường.



Hình 26. Mối liên hệ giữa nhóm độ tuổi và bệnh tiểu đường.

Kết quả : Biểu đồ cho thấy nhóm tuổi từ 9 đến 13 (tương ứng với khoảng 50 tuổi trở lên) có tỉ lệ mắc bệnh tiểu đường cao nhất. điều này suy ra rằng độ tuổi là một yếu tố nguy cơ quan trọng của bệnh tiểu đường. Nguy cơ mắc bệnh tăng lên đáng kể khi tuổi tác tăng cao, đặc biệt là ở những người trên 60 tuổi.

6.2. Mối liên hệ với trình độ học vấn và thu nhập gia đình



Hình 27. Mối liên hệ giữa học vấn và thu nhập gia đình với bệnh tiểu đường.

Kết quả: khi giáo dục ngày càng cao thì số người mắc bệnh tiểu đường ngày càng giảm. những người có thu nhập thấp có nguy cơ mắc bệnh tiểu đường cao hơn những người có thu nhập cao.

Phần V. Lựa chọn đặc trưng

1. Giới thiệu về lựa chọn đặc trưng

Trong bài toán dự đoán nguy cơ mắc bệnh tiểu đường, việc lựa chọn các đặc trưng quan trọng đóng vai trò quan trọng để xây dựng một mô hình hiệu quả và có khả năng khái quát hóa tốt. Lựa chọn đặc trưng giúp giảm thiểu hiện tượng overfitting, cải thiện tốc độ huấn luyện và dự đoán của mô hình. Bằng cách loại bỏ các đặc trưng nhiễu hoặc không liên quan, chúng ta có thể tập trung vào những đặc trưng mang thông tin dự đoán cao nhất, từ đó nâng cao hiệu suất của mô hình.

2. Lựa chọn đặc trưng

2.1 Pearson Correlation

Pearson Correlation: Phương pháp này đo lường mức độ tương quan tuyến tính giữa các đặc trưng và biến mục tiêu Diabetes_binary. Hệ số tương quan Pearson càng cao (gần 1 hoặc -1) thì mối quan hệ tuyến tính càng

mạnh. Các đặc trưng có hệ số tương quan tuyệt đối cao được coi là quan trọng hơn.

Hệ số tương quan có công thức:

$$\rho_{xy} = \frac{\text{Cov}(x, y)}{\sigma_x \sigma_y}$$

Công thức tính hệ số tương quan


Trong đó:

ρ_{xy} : Hệ số tương quan Pearson

$\text{Cov}(x,y)$: Hiệp phương sai (covariance) của biến x và y

σ_x ; σ_y : Độ lệch chuẩn của x và y

Xem thêm: *Hiệp phương sai (covariance) là gì? | Độ lệch chuẩn là gì?*



Hình 28. Hệ số tương quan của các đặc trưng với bệnh tiểu đường.

Các hệ số tương quan được xếp theo giảm dần và giá trị tuyệt đối. Các đặc trưng ở đầu danh sách (GenHlth, HighBP, DiffWalk, BMI) có mức độ tương quan cao nhất với đặc trưng mục tiêu. Điều này cho thấy các đặc trưng này có ảnh hưởng lớn đến việc dự đoán giá trị của đặc trưng mục tiêu. Chúng ta lấy ngưỡng là 0.05 nên sẽ loại bỏ các đặc trưng sau từ smoker

2.2 Giá trị Thông tin (IV)

Giá trị thông tin - Information Value (IV) là một trong những kỹ thuật hữu ích nhất để lựa chọn các biến quan trọng trong mô hình dự đoán. Nó đo lường mối quan hệ giữa một đặc trưng và biến mục tiêu từ đó biết được mức độ quan trọng của chúng[8].

IV được tính bằng công thức sau:

$$IV = \sum_{i=1}^n (W_i - B_i) \cdot \ln \frac{W_i}{B_i}$$


Trong đó:

- W_i : tỷ lệ phần trăm mẫu dương (Positive) nằm trong nhóm i.
- B_i : tỷ lệ phần trăm mẫu âm (Negative) nằm trong nhóm i.
- n : số nhóm được chia từ giá trị của đặc trưng.

Giá trị IV càng cao, khả năng dự đoán của đặc trưng càng lớn trong đó điểm IV có nghĩa là:

Giá trị thông tin	Khả năng dự đoán
< 0.02	Không
0.02 – 0.1	Yếu
0.1 – 0.3	Trung bình
0.3 – 0.5	Mạnh
> 0.5	Tốt một cách bất ngờ

Bảng 3. Khả năng dự đoán giá trị thông tin



Hình 29. Giá trị thông tin các đặc trưng với bệnh tiểu đường.

Kết quả cho thấy các đặc trưng quan trọng được xếp lần lượt từ trên xuống dưới theo các đặc trưng quan trọng là: GenHlth, HighBP, BMI, Age, HighChol, DifWalk, HearDiseadeorAttck, PhysHlth, Income, Educaton, ChoCheck.


2.3 Phương pháp loại bỏ đệ quy Recursive Feature Elimination (RFE)

Loại bỏ tính năng đệ quy (RFE) là một kỹ thuật lựa chọn tính năng được sử dụng trong học máy. Phương pháp là đào tạo lặp đi lặp lại một mô hình và loại bỏ các tính năng ít quan trọng nhất dựa trên tác động của chúng đến hiệu suất của mô hình.[9]

Nguyên lý hoạt động:

- Đánh giá, xếp loại mức độ quan trọng của các đặc trưng: Mỗi đặc trưng trong tập dữ liệu được gán một trọng số (importance score) dựa trên đóng góp của nó vào hiệu suất của mô hình đã chọn.
- Loại bỏ đặc trưng ít quan trọng nhất: Đặc trưng có trọng số thấp nhất sẽ bị loại bỏ khỏi tập dữ liệu.

- Xây dựng lại mô hình bằng cách sử dụng các đặc trưng còn lại
- Lặp lại: Quá trình đánh giá và loại bỏ tiếp tục cho đến khi đạt được số lượng đặc trưng mong muốn hoặc không còn đặc trưng nào để loại bỏ.
- Ưu điểm:
 - Có thể xử lý các tập dữ liệu có chiều cao và xác định các tính năng quan trọng nhất.
 - Có thể xử lý tương tác giữa các tính năng và phù hợp với các tập dữ liệu phức tạp
 - Tương thích với nhiều thuật toán học máy khác nhau.
- Nhược điểm:
 - Tốn thời gian cho các tập dữ liệu lớn hoặc mô hình phức tạp.
 - Mô hình khác nhau có thể có kết quả khác nhau.
 - Có thể không hoạt động tốt với các tính năng có mối tương quan cao.



Hình 30. Các đặc trưng quan trọng sau khi chọn lọc

Kết quả các đặc trưng quan trọng được theo thứ tự từ cao đến thấp, qua biểu đồ có thể thấy các đặc trưng quan trọng được xếp theo thứ tự là: BMI, Age, Income, PhysHlth,

Kết luận: Sau khi áp dụng các phương pháp đã thấy được sự phản ánh tương quan giữa các đặc trưng với bệnh tiểu đường. Chúng ta đã xác định được các đặc trưng ít quan trọng hơn: Smoker, HvyAlcoholConsump, Stroke, HeartDiseaseorAttack, AnyHealthcare, NoDocbcCost, Veggies, Fruits, Sex

Các đặc trưng quan trọng nhất cho mô hình dự đoán bệnh tiểu đường gồm : HighBP, HighChol, BMI, GenHlth, Age, DiffWalk, PhysHlth, Income, Education, PhysActivity. Việc tập trung vào các đặc trưng này trong mô hình dự đoán sẽ giúp cải thiện độ chính xác và hiệu quả của mô hình.

Phần VI. Huấn luyện mô hình

1. Chia dữ liệu huấn luyện

Trước khi huấn luyện mô hình, chúng ta cần chia tập dữ liệu thành hai phần: tập huấn luyện (training) và tập kiểm tra (testing). Tập huấn luyện được sử dụng để huấn luyện mô hình, còn tập kiểm tra được sử dụng để đánh giá hiệu suất của mô hình .

Trong bài toán này, chúng ta sẽ chia dữ liệu theo tỉ lệ 80/20, tức là 80% dữ liệu được sử dụng để huấn luyện và 20% dữ liệu được sử dụng để kiểm tra. Và sẽ chia dữ liệu theo từng biến mục tiêu (stratify) để đảm bảo tỷ lệ các lớp trong biến mục tiêu được giữ nguyên trong cả tập huấn luyện và tập kiểm tra. Việc này giúp tránh trường hợp tập huấn luyện hoặc tập kiểm tra chỉ chứa một lớp duy nhất, dẫn đến mô hình không thể học được cách phân loại cho các lớp khác. Đặc biệt trong dữ liệu bị mất cân bằng về phân lớp, như trong trường hợp của bài toán này (số lượng người không mắc bệnh tiểu đường nhiều hơn số lượng người mắc bệnh).

Chúng ta sẽ sử dụng **hàm train_test_split** từ thư viện **sklearn.model_selection** để thực hiện việc chia dữ liệu, với tham số stratify được đặt là biến mục tiêu y.

```
from sklearn.model_selection import train_test_split

#chia dữ liệu với tất cả các đặc trưng gốc

df_X = df.drop('Diabetes_binary', axis=1)

df_y = df['Diabetes_binary']

X_train_goc, X_test_goc, y_train, y_test = train_test_split(df_X, df_y,
test_size=0.2,stratify=df_y , random_state=42)

# Chia dữ liệu với các đặc trưng đã chọn lọc
selected_features = ['HighBP', 'HighChol', 'BMI', 'GenHlth', 'Age', 'DiffWalk',
'PhysHlth', 'Income', 'Education', 'PhysActivity']

X = df[selected_features]

df_y = df['Diabetes_binary']

X_train_chonloc, X_test_chonloc, y_train, y_test = train_test_split(X, df_y,
test_size=0.2, stratify=y, random_state=42)
```

Trong đó:

- df_X: Ma trận đặc trưng gốc
- X: Ma trận các đặc trưng đã chọn
- df_y: Vector mục tiêu.
- test_size: Tỷ lệ dữ liệu được sử dụng để kiểm tra (ở đây là 0.2, tương ứng với 20%).
- random_state: Giá trị khởi tạo cho bộ tạo số ngẫu nhiên, giúp đảm bảo kết quả có thể tái tạo.
- stratify=y: Tham số chỉ định chia dữ liệu theo từng lớp trong biến mục tiêu y.

2. Huấn luyện mô hình cây quyết định

2.1 Lý do chọn mô hình randomforest cho bài toán

RandomForest được lựa chọn cho bài toán dự đoán bệnh tiểu đường vì nó là một thuật toán mạnh mẽ, linh hoạt và hiệu quả. Với các ưu điểm nổi bật như:

- Hiệu suất dự đoán cao và khả năng khái quát hóa tốt trên nhiều loại dữ liệu.
- Giảm thiểu overfitting nhờ việc kết hợp nhiều cây quyết định.
- Xử lý hiệu quả dữ liệu bị thiếu, một vấn đề thường gặp trong dữ liệu thực tế.
- Cung cấp thông tin về tầm quan trọng của các đặc trưng, giúp hiểu rõ hơn về dữ liệu.

Vì vậy RandomForest là một lựa chọn phù hợp cho bài toán dự đoán bệnh tiểu đường của chúng em.

2.2 Huấn luyện mô hình.

Để đánh giá hiệu quả của việc chọn lọc đặc trưng, chúng ta sẽ huấn luyện mô hình RandomForest với hai tập đặc trưng khác nhau: đặc trưng gốc và đặc trưng đã chọn lọc.

- Các siêu tham số ban đầu của mô hình:
 - `n_estimators=10`: số lượng cây quyết định trong rừng ngẫu nhiên là 10 cây.
 - `random_state=42`: Siêu tham số này được sử dụng để đảm bảo tính tái lập của kết quả.

Huấn luyện mô hình với các đặc trưng gốc

```
from sklearn.ensemble import RandomForestClassifier
```

```
# Khởi tạo mô hình
model_rf_goc = RandomForestClassifier(n_estimators=10, random_state=42)

# Huấn luyện mô hình với đặc trưng gốc
model_rf_goc.fit(X_train_goc, y_train)
```

Huấn luyện mô hình với các đặc trưng đã chọn

Các đặc trưng đã được chọn lọc ở phần IV chọn lọc đặc trưng:

```
selected_features = ['HighBP', 'HighChol', 'GenHlth', 'PhysActivity', 'DiffWalk',
                    'BMI', 'Age', 'Income', 'PhysHlth', 'Education']
```

huấn luyện:

```
model_chonloc = RandomForestClassifier(n_estimators=10, random_state=42)

model_chonloc.fit(X_train_chonloc, y_train)
```

Phần VII. Đánh giá mô hình

1. Phép đo sử dụng đánh giá

Chúng em sử dụng chỉ số F1-score để đánh giá mô hình trong bài toán này vì :

- Dữ liệu của chúng ta trong bài toán này bị mất cân bằng, trong trường hợp này sử dụng F1-score hiệu quả hơn Accuracy.
- F1-score cân bằng giữa Precision (độ chính xác) và Recall (độ nhạy), cả hai đều quan trọng trong việc dự đoán bệnh tiểu đường. Precision cao đảm bảo giảm thiểu dự đoán sai, trong khi Recall cao đảm bảo phát hiện được nhiều trường hợp mắc bệnh nhất có thể.
- F1-score sẽ giúp đánh giá hiệu suất tổng thể của mô hình một cách toàn diện hơn trên cả hai lớp (mắc bệnh và không mắc bệnh), thay vì chỉ tập trung vào lớp chiếm đa số.

- F1-score có công thức :

$$F_1 = 2 \frac{precision \times recall}{precision + recall}$$

Với :

- PRECISION: Phần trăm của những phân loại dương tính mà đúng:

$$precision = \frac{TP}{TP + FP}$$

- RECALL: Phần trăm của những mẫu dương tính mà được phân loại chính xác:

$$recall = \frac{TP}{TP + FN}$$

- TN (True Negative), FP (False Positive), FN (False Negative) và TP (True Positive).

2. Đánh giá kết quả

Các đặc trưng gốc					Lựa chọn các đặc trưng				
Accuracy: 0.8380869375748993					Accuracy: 0.8261466390674366				
	precision	recall	f1-score			precision	recall	f1-score	
0	0.86	0.96	0.91		0	0.87	0.94	0.90	
1	0.44	0.17	0.24		1	0.38	0.20	0.26	
accuracy			0.84		accuracy			0.83	
macro avg	0.65	0.56	0.58		macro avg	0.62	0.57	0.58	
weighted avg	0.80	0.84	0.81		weighted avg	0.79	0.83	0.80	

Bảng 4. So sánh hiệu suất mô hình

Kết quả:

Accuracy giảm nhẹ: Mặc dù mô hình sau khi lựa chọn đặc trưng có độ chính xác giảm nhẹ (từ **0.838** xuống **0.826**), đây là điều thường thấy khi giảm số lượng đặc trưng. Điều này có thể do một số thông tin ít hữu ích bị loại bỏ trong quá trình chọn lọc đặc trưng.

F1-score của lớp 1 tăng nhẹ: F1-score (lớp 1) tăng từ **0.24** lên **0.26**, cho thấy việc lựa chọn đặc trưng đã giúp mô hình tập trung hơn vào các đặc trưng quan trọng, phần nào cải thiện khả năng phân loại lớp không phổ biến (lớp 1).

F1-score của lớp 0 giảm nhẹ: F1-score (lớp 0) giảm từ **0.91** xuống **0.90**, nhưng đây là một sự đánh đổi hợp lý nếu mô hình cần cải thiện hiệu suất trên lớp 1.

Macro avg F1-score không đổi: Macro avg F1-score giữ nguyên ở **0.58**, cho thấy hiệu suất tổng quát của mô hình trên các lớp không thay đổi nhiều, nhưng sự cân bằng giữa các lớp được cải thiện đôi chút.

Weighted avg F1-score giảm từ 0.81 xuống 0.80.

Từ những so sánh trên có thể thấy mặc dù mô hình sau khi lựa chọn ra các đặc trưng có sự thay đổi nhẹ điểm f1-score của hai lớp. nhưng điểm avg f1-score thì không đổi. cho thấy hiệu quả của việc loại bỏ các đặc trưng.

Phần VIII. Tinh chỉnh mô hình

1. Tìm bộ tham số tối ưu

Sử dụng phương pháp lựa chọn tham số GridSearchCV cho mô hình RandomForest, đây là công cụ trong thư viện scikit-learn.

GridSearchCV hoạt động dựa trên việc tạo ra một lưới (grid) gồm tất cả các tổ hợp tham số có thể từ một danh sách các giá trị cung cấp trước. Sau đó, nó huấn luyện và đánh giá mô hình với từng tổ hợp tham số, tìm ra tổ hợp tốt nhất dựa trên một tiêu chí đánh giá.

Tạo lưới các siêu tham số quan trọng của RandomForest:

- `n_estimators`: Số lượng cây quyết định trong rừng.
- `max_depth`: Độ sâu tối đa của mỗi cây quyết định.
- `min_samples_split`: Số lượng mẫu tối thiểu cần thiết để phân chia một nút.
- `min_samples_leaf`: Số lượng mẫu tối thiểu cần thiết để tạo một lá.

- `max_features`: Số lượng đặc trưng được xem xét khi tìm kiếm điểm phân chia tốt nhất.
- Tiêu chí đánh giá: F1-score

```
from sklearn.model_selection import GridSearchCV

#xác định các tham số

param_grid = {

    'n_estimators': [10,20 ,50 ],

    'max_depth': [None, 5, 10],

    'min_samples_split': [2, 5, 10],

    'min_samples_leaf': [1, 2, 5],

    'max_features': ['auto', 'sqrt', 'log2']

}

#Khởi tạo và huấn luyện GridsearchCV

grid_search = GridSearchCV(

    estimator=RandomForestClassifier(random_state=42),

    param_grid=param_grid,

    scoring='f1',          # Sử dụng F1-score làm thước đo đánh giá

    cv=5,                  # Sử dụng 5-fold cross-validation

    n_jobs=-1              # Sử dụng tất cả các core CPU để tăng tốc độ

)

grid_search.fit(X_train, y_train)

print("Best parameters:", grid_search.best_params_)
```


Kết quả:

Best parameters: {'max_depth': None, 'max_features': 'sqrt',
'min_samples_leaf': 1, 'min_samples_split': 5, 'n_estimators': 10}

2. Huấn luyện lại mô hình với tham số tối ưu.

```
best_params = grid_search.best_params_  
  
model_rf_optimized = RandomForestClassifier(**best_params,  
random_state=42)  
  
model_rf_optimized.fit(X_train, y_train)  
  
y_pred_optimized = model_rf_optimized.predict(X_test)  
  
accuracy_optimized = accuracy_score(y_test, y_pred_optimized)  
  
print(f'Optimized Random Forest Accuracy: {accuracy_optimized}')  
print(classification_report(y_test, y_pred_optimized))
```

kết quả:

```
Optimized Random Forest Accuracy: 0.8361259396448415  
              precision    recall  f1-score   support  
  
    0           0.87       0.95       0.91       38876  
    1           0.43       0.21       0.28        7019  
  
   accuracy                   0.84       45895  
  macro avg           0.65       0.58       0.59       45895  
 weighted avg           0.80       0.84       0.81       45895
```

Hình 31. Kết quả tinh chỉnh.

Sau khi tinh chỉnh mô hình với các tham số tìm được bằng phương pháp GridSearchCV, Điểm F1-score macri avg đã tăng nhẹ lên từ 0.58 lên 0.59 cho thấy sự cân bằng giữa các lớp đã được cải thiện hơn.

Phần IX. Kết luận

1. Tóm tắt

Bài báo cáo này đã trình bày quá trình xây dựng mô hình dự đoán bệnh tiểu đường dựa trên tập dữ liệu BRFSS2015. Thông qua các bước phân tích dữ liệu, chọn lọc đặc trưng, huấn luyện mô hình và tinh chỉnh tham số, đã đạt được những kết quả khả quan.

- **Kết quả chính:**

Phân tích dữ liệu: Thông qua các biểu đồ và các phương pháp thống kê, chúng ta đã khám phá được các mối quan hệ giữa các đặc trưng và biến mục tiêu (bệnh tiểu đường). Ví dụ, chúng ta đã thấy mối tương quan giữa các yếu tố như huyết áp cao, cholesterol cao, BMI, tuổi tác và nguy cơ mắc bệnh tiểu đường.

- **Lựa chọn đặc trưng:** Sử dụng các kỹ thuật như Correlation, Information Value, loại bỏ đệ quy Recursive Feature Elimination (RFE) đã chọn lọc được một tập hợp các đặc trưng quan trọng nhất để đưa vào huấn luyện mô hình, giúp giảm thiểu độ phức tạp, tăng tốc huấn luyện và cải thiện hiệu suất dự đoán của mô hình.
- **Huấn luyện mô hình:** Mô hình RandomForest được lựa chọn và huấn luyện dựa trên tập dữ liệu đã được chọn lọc xử lý. Và đạt số điểm với F1-score là 0.58 và số điểm accuracy là 0.83.
- **Tinh chỉnh mô hình:** Phương pháp GridSearchCV được sử dụng để tìm kiếm bộ siêu tham số tối ưu cho mô hình RandomForest, giúp cải thiện thêm hiệu suất dự đoán của các lớp, và điểm F1-score từ 0.58 lên 0.59

2. Hạn chế và hướng phát triển

- Mô hình được xây dựng dựa trên tập dữ liệu BRFSS2015, có thể không phản ánh đầy đủ đặc điểm của quần thể khác. Cần tiếp tục nghiên cứu và phát triển mô hình trên các tập dữ liệu đa dạng hơn.
- Cần bổ sung thêm dữ liệu của lớp dữ liệu bị mắc bệnh tiểu đường cho dữ liệu cân bằng hơn

- Hiệu suất của mô hình có thể được cải thiện bằng cách áp dụng các kỹ thuật học máy tiên tiến hơn, ví dụ như học sâu (deep learning).
- Cần kết hợp với các yếu tố khác như tiền sử gia đình, lối sống để đưa ra dự đoán chính xác hơn.

3. Kết luận chung

Trong bài báo cáo chúng em đã sử dụng các kỹ thuật phân tích và nhận dạng mẫu trong việc xây dựng mô hình dự đoán bệnh tiểu đường. Mô hình đạt được hiệu suất khả quan và có tiềm năng ứng dụng trong thực tiễn để giúp phát hiện sớm và kiểm soát bệnh tiểu đường hiệu quả hơn. Tuy nhiên, cần tiếp tục nghiên cứu và phát triển để hoàn thiện mô hình hơn nữa.

Tài liệu tham khảo

- [1] T. X. . Nguyễn và Đinh A. . Lê, “MỐI LIÊN QUAN MỘT SỐ TRIỆU CHỨNG LÂM SÀNG VỚI TỶ LỆ TỬ VONG MẠC Ở BỆNH NHÂN ĐÁI THÁO ĐƯỜNG TÝP 2”, *VMJ*, vol 524, số p.h 2, tháng 3 2023.
- [2] I. Rahman, N. Ullah, A. Dad, and I. Ali, “Knowledge, Awareness of Diabetes Mellitus in Nurses Working in Tertiary Care Hospital of Peshawar: Diabetes Knowledge among Nurses”, *NRS*, vol. 4, no. 02, pp. 17–22, Jun. 2024.
- [8] Chen, M., Zhang, Z., & Zhang, Y. (2020). "Application of Information Value in Feature Selection for Machine Learning Models". *Journal of Statistical Analysis*.
- [8] Listendata, "Weight of Evidence (WOE) and Information Value (IV)," 2015. Available: <https://www.listendata.com/2015/03/weight-of-evidence-woe-and-information.html>. [đã truy cập: 14-12 -2024].
- [3][5] . Philips, "Predictive analytics in healthcare: Three real-world examples," Philips, n.d. [Online]. Available: <https://www.philips.com>.
- [4]. HealthITAnalytics, "Artificial intelligence in cancer detection," Health IT Analytics, 2023. Available: <https://www.healthitanalytics.com>. [đã truy cập: 14-12-2024]
- [9] Scikit-learn, "sklearn.feature_selection.RFE," *Scikit-learn Documentation*. Available: https://scikit-learn.org/stable/modules/generated/sklearn.feature_selection.RFE.html. [đã truy cập : 14-12 -2024].
- [9] Analytics Vidhya, "Recursive Feature Elimination: A Feature Selection Method," *Analytics Vidhya Blog*. Available: <https://www.analyticsvidhya.com/blog/2023/05/recursive-feature-elimination/>. [đã truy cập: 20-12 -2024].

[6] O. Mosenzon et al., "Associations Between Diabetes Mellitus and Stroke Risk," *Frontiers in Neurology*, vol. 13, Article PMC9911852, Dec. 2022.

Available: <https://pmc.ncbi.nlm.nih.gov/articles/PMC9911852/>. [đã truy cập: 20-12 -2024].